実験 I-C・逐次観測方策 PoC

一度しかない観測機会に、有限な注意をどう配分するか

Toru Takahashi

v0.1 / 2026 年 8 月

この実験で確かめること

実験 I-B では、観測前の欠落と、観測後の表現圧縮を分けて測った。しかし観測先は Oracle が与えていた。本 PoC は、毎時刻 A/B の一方だけを見る逐次環境を作り、何を保存したいかに応じて観測方策を学習する。同時刻に見なかった値は後から取得できず、下流の推定器を改良しても完全には戻らない。

推奨環境は Google Colab の標準 CPU である。GPU、オープンモデル、大容量データ、有料クラウドは使わない。同梱コードは NumPy のみに依存し、full 設定も通常の CPU で数十秒以内に終了する。

目次

1 実験 I-B からの進展 2

2 生成データと時間的重要度 2

3 六つの比較条件 3

4 要因計画と工学的ゲート 3

5 検証済み full 結果 4

6 共同更新の利得が出なかった意味 5

7 Google Colab 実行手順 5

7.1 用意するファイル 5

7.2 実行 5

7.3 出力の読み方 6

8 結論と次の実験 6

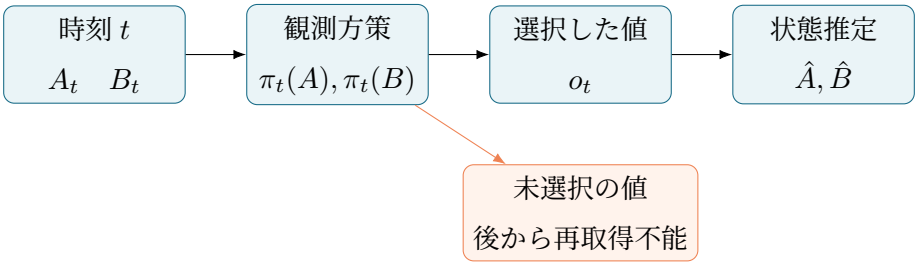
1　実験 I-B からの進展

実験 I-B は、観測作用 $\mathcal{A}_S$ で選ばれなかったチャネルが、後段の表現容量 C_R を増やしても回復しないことを確かめた。ただし、どのチャネルを見るかは、全候補を列挙する Oracle が決めていた。

本実験は観測を時間上に展開する。時刻 $t = 1, \ldots, T$ に A 側と B 側の値が同時に生じるが、行為主体は一方しか観測できない。

$$a_t \in \{A, B\}, \qquad o_t = x_{t,a_t}, \qquad x_{t,\bar{a}_t} \notin o_{\leq T}. \tag{1}$$

$\bar{a}_t$ は選ばなかった側を表す。この式の要点は、見なかった同時刻の値が、後の観測履歴の中に存在しないことである。取得後の圧縮ではなく、一度性を持つ観測機会の配分を対象にする。



この PoC がまだ示さないこと

A/B は、心理志向／客観志向などの意味を持つ軸ではなく、競合する二つの信号源である。方策も現在状態に応じて変わらず、時刻だけに依存する。ここで校正するのは、逐次的な取得機会と観測方策の測定基盤である。

2　生成データと時間的重要度

$T = 4$ とし、各時刻で相関する A/B 信号を生成する。

$$A_t \sim \mathcal{N}(0, 1), \tag{2}$$

$$B_t = \rho A_t + \sqrt{1 - \rho^2}\, \varepsilon_t, \qquad \varepsilon_t \sim \mathcal{N}(0, 1), \quad \rho = 0.35. \tag{3}$$

観測値には標準偏差 0.05 の独立ノイズを加える。A/B の値自体は各時刻で対称だが、評価で使う時間的重要度は反転させる。

	$t = 1$	$t = 2$	$t = 3$	$t = 4$
A の重み w_t^A	1.8	1.4	0.6	0.2
B の重み w_t^B	0.2	0.6	1.4	1.8

この設計により、A を重視するなら前半の A 観測が、B を重視するなら後半の B 観測が有利になる。両方を同じ重みで保存する場合は、前半で A、後半で B を見る「AABB」が候補になる。ただし、コー

ドはこの答えを与えず、方策学習が自力で収束できるかを測る。

推定対象は A/B の時系列全体である。最適線形読み出しの正規化二乗誤差を時間重みで平均し、

$$D_A = \frac{\sum_t w_t^A \,\mathrm{NMSE}(A_t, \hat{A}_t)}{\sum_t w_t^A}, \tag{4}$$

$$D_B = \frac{\sum_t w_t^B \,\mathrm{NMSE}(B_t, \hat{B}_t)}{\sum_t w_t^B}, \tag{5}$$

$$J_\lambda = \lambda D_A + (1-\lambda) D_B \tag{6}$$

とする。$\lambda = 1$ は A だけ、$\lambda = 0$ は B だけ、$\lambda = 0.5$ は両者を同じ重みで保存する条件である。

3　六つの比較条件

方策が学習できたかだけでは、何が利得を生んだか分からない。そこで、上限、下限、特化、下流固定、共同更新を分ける。

条件	役割
full observation	毎時刻 A/B の両方を見る。時間的な観測制約のない床。
Oracle	$2^4 = 16$ 通りの固定スケジュールを列挙し、検証データで最良を選ぶ。学習方策の上限対照。
random fixed	各時刻 A/B を等確率で選ぶ。保存要求を用いない基準。
A fixed / B fixed	四時刻すべてで一方を見る。目的が偏った場合の特化対照。
learned / frozen	ランダム方策下で作った推定器を固定し、観測方策だけを更新する。方策単独の寄与を測る。
learned / joint	現在の方策分布の下で最適線形推定器を当て直し、方策と下流推定の最小循環を作る。

学習方策は時刻ごとの二値 softmax である。

$$\pi_\theta(a_{1:T}) = \prod_{t=1}^{T} \pi_{\theta,t}(a_t), \qquad a_t \in \{A, B\}. \tag{7}$$

全 16 スケジュールを列挙できるため、Monte Carlo サンプリングは使わない。目的値の期待値

$$\mathcal{J}(\theta) = \sum_s \pi_\theta(s) L(s) \tag{8}$$

とその方策勾配を厳密に計算し、Adam でロジットを更新する。共同更新条件では、その反復の方策分布に対する最適推定器を十分統計量から解く。

4　要因計画と工学的ゲート

事前に固定した校正ゲートは次のとおりである。

表 2　実行条件

項目	設定
時刻数	4
相関 ρ	0.35
観測ノイズ	0.05
λ	0, 0.25, 0.5, 0.75, 1
quick	学習 2,048、検証 1,024、評価 1,024、5 seed
full	学習 8,192、検証 4,096、評価 4,096、20 seed
必要環境	CPU、NumPy、メモリ数 GB 未満

1. 全観測条件の平均歪みが 0.01 未満である。
2. $\lambda = 0.5$ で Oracle 逐次観測の歪みが全観測より 0.05 以上大きい。
3. 内点 $\lambda \in \{0.25, 0.5, 0.75\}$ で、共同更新方策の Oracle との差が 0.04 未満である。
4. 共同更新方策がランダムを 0.05 以上上回る。
5. 下流固定方策もランダムを 0.03 以上上回る。
6. 共同更新方策の最頻スケジュールが Oracle と 80% 以上一致する。
7. A/B 特化対照の優劣が λ に応じて反転する。

これらは人間の志向性の統計検定ではない。逐次観測、歪み評価、方策最適化、対照条件が想定した関係で動くかを確かめる工学的ゲートである。

5　検証済み full 結果

20 seed の full 設定は全ゲートを通過した。$\lambda = 0.5$ の主要結果を表 3 に示す。

全観測と Oracle 逐次観測の差は 0.1750 であった。これは、一時刻に一方しか見られないことの機会費用である。観測方策と下流推定をどれだけ最適化しても、同時刻に見なかった専用情報は完全には回復しない。

学習方策は内点でランダム方策を 0.2773 上回り、Oracle との差は 0.0001 であった。最頻スケジュールは全 20 seed で Oracle と一致した。

λ	0	0.25	0.5	0.75	1
Oracle	BBBB	ABBB	AABB	AAAB	AAAA
学習／固定	BBBB	ABBB	AABB	AAAB	AAAA
学習／共同	BBBB	ABBB	AABB	AAAB	AAAA

表 3　$\lambda = 0.5$ の平均歪み（full、低いほど良い）

方法	$J_{0.5}$	D_A	D_B
全観測	0.0025	0.0025	0.0025
Oracle	0.1775	0.1771	0.1779
A 特化固定	0.4402	0.0025	0.8779
B 特化固定	0.4405	0.8785	0.0025
ランダム固定	0.4402	0.4404	0.4401
学習／下流固定	0.1775	0.1771	0.1780
学習／共同更新	0.1775	0.1771	0.1779

この結果は、保存要求の重みが変わると、同じ観測環境でも「いつ何を見るか」が系統的に変わることを校正上の予測どおり示している。

6　共同更新の利得が出なかった意味

下流固定と共同更新の差は、内点平均で約 0.0001 に過ぎなかった。これを「共同更新が成功した」とは解釈しない。

本環境では、A/B の観測チャネルと推定対象が線形に対応している。ランダム方策下で学習した推定器も、選択された各チャネルを既に十分復号できる。そのため、方策が変わっても、下流推定器を当て直す固有利得がほとんどない。

この無差は、後続実験の対照点になる。現在状態によって有用な観測先が変わり、過去の観測分布が表現器の専門化を生む環境では、固定条件と共同更新条件に差が出る可能性がある。次の問いは、どの条件でその差が必要になるかである。

7　Google Colab 実行手順

7.1　用意するファイル

ZIP を展開し、次の二つを手元に置く。

- `colab_runner.ipynb`
- `sequential_policy_poc.py`

7.2　実行

1. Google Colab を開き、「アップロード」から `colab_runner.ipynb` を選ぶ。

2. 最初のコードセルを実行し、表示されたファイル選択で `sequential_policy_poc.py` を選ぶ。
3. 二番目のセルを実行する。既定は `--quick` で、数秒〜数十秒で終了する。
4. 実行終了後、自動判定、方策別性能図、観測確率図を確認する。
5. 最後のセルで結果 ZIP をダウンロードする。

quick が成功した後、実行セルの `--quick` を `--full` に変えると 20 seed で再確認できる。GPU ランタイムに切り替える必要はない。

7.3 出力の読み方

- `result_report.md`：ゲート判定、主要数値、最頻スケジュール。
- `policy_performance.svg`：λ ごとの Oracle、ランダム、二つの学習方策の歪み。
- `learned_policy.svg`：共同更新条件が時刻ごとに A を見る確率。
- `summary_results.csv`：条件ごとの平均と標準偏差。
- `raw_results.csv`：seed 別の歪み、最頻スケジュール、Oracle との一致率。
- `policy_probabilities.csv`：時刻別の A/B 観測確率。
- `learning_history.csv`：反復中の目的値と方策エントロピー。

8 結論と次の実験

本 PoC は、静的な「どのチャネルを残すか」から、時間的な「いつ何を見るか」へ一歩進んだ。保存要求に応じた方策が Oracle と同じスケジュールへ収束し、見逃した時刻の情報に明確な機会費用が生じた。

ただし、これは開ループ方策の校正である。次の非自明な段階では、観測前の信念状態や部分観測によって、次に見るべき対象が変わる環境を用いる。そこで、

1. 現在状態に条件づけられた閉ループ観測方策、
2. Oracle、ランダム、A/B 特化の固定方策対照、
3. 下流固定と共同更新の差が生じる条件、
4. 初期の観測履歴が後の方策と表現に残るか

を問う。この段階で初めて、観測方策と世界表現の学習が互いの条件を変える循環に近づく。